

Introducción a ML y Probabilidad/Estadística

¿Qué es aprender de datos? Matemática básica

Agustín Gurvich

Introducción a Machine Learning

Parte I

Introducción a Machine Learning

¿Qué es Machine Learning?

Definición

El machine learning es un subconjunto de la inteligencia artificial centrado en algoritmos que pueden **aprender** los patrones de los datos de entrenamiento y hacer inferencias precisas sobre nuevos datos.

¿Qué es Machine Learning?

Definición

El machine learning es un subconjunto de la inteligencia artificial centrado en algoritmos que pueden **aprender** los patrones de los datos de entrenamiento y hacer inferencias precisas sobre nuevos datos.

En vez de escribir reglas a mano, le mostramos ejemplos al modelo y este **aprende un patrón** que generaliza a casos nuevos.

Programación tradicional vs. ML

Programación tradicional

- Le damos datos y definimos reglas. Eso nos da *resultados*
- Nosotros escribimos la lógica

Machine Learning

- Le damos datos y resultados. Eso nos da *reglas*
- El modelo aprende la lógica

¿Dónde se usa?

- Recomendaciones (Netflix, Spotify, YouTube)
- Detección de spam
- Reconocimiento de imágenes y voz
- Diagnóstico médico asistido
- Autos autónomos
- Traducción automática

Aprendizaje supervisado

Definición

Aprendemos una función que asocia entradas a salidas, a partir de ejemplos **etiquetados**.

Ejemplo

Predecir el precio de una casa a partir de sus características (m^2 , ubicación, antigüedad), usando casas ya vendidas como ejemplo.

Se suelen usar en dos tipos de problemas: **clasificación** (categorías) y **regresión** (valores numéricos continuos).

Aprendizaje no supervisado

Definición

Buscamos patrones o estructura en datos **sin etiquetas**.

Ejemplo

Agrupar clientes de una tienda según sus hábitos de compra, sin saber de antemano qué grupos existen (clustering).

Aprendizaje por refuerzo

Definición

Un agente aprende a tomar decisiones interactuando con un entorno, recibiendo recompensas o castigos.

Ejemplo

Un programa que aprende a jugar al go o a un videojuego jugando muchas partidas contra sí mismo.

¿Cómo es el flujo de trabajo en un proyecto de ML?

¿Cómo se imaginan que trabaja un ingeniero de ML?

¿Cómo es el flujo de trabajo en un proyecto de ML?

¿Cómo se imaginan que trabaja un ingeniero de ML?

- 1 Definir el problema
- 2 Recolectar y explorar los datos
- 3 Preprocesar los datos (limpieza, transformación)
- 4 Elegir un modelo y entrenarlo
- 5 Evaluar el modelo
- 6 Ajustar (iterar) y poner en producción

¿Cómo es el flujo de trabajo en un proyecto de ML?

¿Cómo se imaginan que trabaja un ingeniero de ML?

- 1 Definir el problema
- 2 Recolectar y explorar los datos
- 3 Preprocesar los datos (limpieza, transformación)
- 4 Elegir un modelo y entrenarlo
- 5 Evaluar el modelo
- 6 Ajustar (iterar) y poner en producción

Importante

La mayor parte del tiempo real de un proyecto de ML se va en los datos, no en el modelo.

Palabras que van a escuchar mucho

- **Dataset:** conjunto de datos con los que trabajamos
- **Feature:** cada variable de entrada
- **Target (etiqueta):** lo que queremos predecir
- **Modelo:** la función/algorithmo que aprende el patrón
- **Entrenamiento:** proceso de ajustar el modelo a los datos
- **Overfitting:** el modelo memoriza en vez de generalizar

Parte II

Probabilidad y Estadística para ML

¿Por qué necesitamos estadística?

Importante

ML (y la computación en general) es, en el fondo, matemática aplicada a gran escala. Todo dataset es una muestra, y todo modelo hace operaciones estadísticas sobre esa muestra.

- Para **entender** los datos antes de modelar (¿hay outliers? ¿están sesgados?)
- Para **elegir** qué transformar y cómo
- Para **interpretar** si un resultado es significativo o casualidad

- **Media** ($\bar{x}$): promedio de los valores

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Mediana**: valor que queda en el medio al ordenar los datos
- **Moda**: valor más frecuente

Medidas de tendencia central

- **Media** ($\bar{x}$): promedio de los valores

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- **Mediana**: valor que queda en el medio al ordenar los datos
- **Moda**: valor más frecuente

Ejemplo

Sueldos: 1, 1, 2, 2, 2, 100 (en cientos de miles). Media ≈ 18 , mediana = 2, moda = 2. La media se deja engañar por valores extremos, la mediana no.

- **Varianza:** qué tan lejos están los datos de la media, en promedio (al cuadrado)

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **Desvío estándar:** $\sigma = \sqrt{\sigma^2}$, en las mismas unidades que los datos

- **Varianza:** qué tan lejos están los datos de la media, en promedio (al cuadrado)

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

- **Desvío estándar:** $\sigma = \sqrt{\sigma^2}$, en las mismas unidades que los datos

Importante

Un desvío estándar grande dice que los datos están muy dispersos! La media sola no alcanza para describir un dataset.

La distribución normal

- Forma de **campana**, simétrica alrededor de la media
- Muchísimos fenómenos naturales se aproximan a esta forma (alturas, errores de medición)
- Muchos algoritmos de ML **asumen** (implícita o explícitamente) que las variables se comportan así

Probabilidad: lo mínimo indispensable

- **Probabilidad:** número entre 0 y 1 que mide qué tan posible es un evento
- **Probabilidad condicional** $P(A \mid B)$: probabilidad de A sabiendo que B ya ocurrió

Ejemplo

$P(\text{spam})$ = probabilidad general de que un mail sea spam.

$P(\text{spam} \mid \text{contiene "gratis"})$ = probabilidad de spam *sabiendo* que el mail contiene la palabra "gratis". Mucho más útil.

Correlación

Definición

La correlación mide qué tan relacionadas están dos variables numéricas, con un valor entre -1 y 1 .

- Cerca de 1 : cuando una sube, la otra también (relación positiva)
- Cerca de -1 : cuando una sube, la otra baja (relación negativa)
- Cerca de 0 : no hay relación lineal aparente

Importante

Correlación no implica causalidad.

¿Preguntas?