

Python Científico y Preprocesamiento de Datos

numpy, pandas, matplotlib y preparar datos para un modelo

Agustín Gurvich

Introducción a Machine Learning

Parte I

Python científico

¿Por qué no alcanza con Python puro?

- Las listas de Python no fueron pensadas para hacer cuentas con miles o millones de números
- Para trabajar con datos en serio usamos tres librerías:
- **numpy**: vectores y matrices de números
- **pandas**: tablas (filas y columnas)
- **matplotlib**: gráficos

¿Por qué no alcanza con Python puro?

- Las listas de Python no fueron pensadas para hacer cuentas con miles o millones de números
- Para trabajar con datos en serio usamos tres librerías:
- **numpy**: vectores y matrices de números
- **pandas**: tablas (filas y columnas)
- **matplotlib**: gráficos

Importante

Casi toda librería de ML en Python, incluyendo scikit-learn, está construida arriba de numpy y pandas.

Definición

Un array de numpy es una lista de números que se puede operar directamente, sin escribir loops.

```
import numpy as np

x = np.array([1, 2, 3, 4])
x * 2
# array([2, 4, 6, 8])
```

numpy: operaciones sin loops

```
edades = np.array([15, 16, 17, 18, 17])

edades.mean()      # 16.6
edades.std()       # desvio estandar
edades.max()       # 18
edades[edades > 16] # array([17, 18, 17])
```

numpy: operaciones sin loops

```
edades = np.array([15, 16, 17, 18, 17])

edades.mean()      # 16.6
edades.std()       # desvio estandar
edades.max()       # 18
edades[edades > 16] # array([17, 18, 17])
```

Importante

Nada de for. Estas operaciones se aplican a todo el array de una, y son mucho más rápidas que un loop escrito a mano.

Definición

Un DataFrame es una tabla: filas y columnas, con nombres, donde cada columna puede tener un tipo de dato distinto (números, texto, fechas).

```
import pandas as pd

df = pd.read_csv("datos.csv")
df.head()    # primeras 5 filas
```

pandas: elegir y filtrar

```
df["edad"]                # una columna
df[["edad", "nota"]]      # varias columnas

df[df["edad"] > 17]        # filas que cumplen una condicion
```

pandas: funciones que van a usar seguido

- `df.info()`: tipos de datos y valores faltantes
- `df.describe()`: media, desvío, mínimo, máximo de cada columna
- `df.groupby(columna)`: agrupar filas por un valor
- `df.sort_values(columna)`: ordenar

```
import matplotlib.pyplot as plt

fig, ax = plt.subplots()
ax.scatter(df["edad"], df["nota"])
plt.show()
```

```
import matplotlib.pyplot as plt

fig, ax = plt.subplots()
ax.scatter(df["edad"], df["nota"])
plt.show()
```

fig es el lienzo entero, ax es donde se dibuja. Ya lo probamos con el dataset Iris.

Resumen: numpy, pandas, matplotlib

- numpy: cuentas rápidas sobre números, sin loops
- pandas: tablas, filtrar, agrupar, resumir
- matplotlib: ver los datos antes y después de modelar

Parte II

Preprocesamiento de datos

Importante

Ningún modelo entrena bien con datos sucios. En un proyecto real, esta parte suele llevar más tiempo que elegir y entrenar el modelo.

Antes de entrenar cualquier cosa hay que resolver al menos tres problemas típicos:

- 1 Datos faltantes
- 2 Variables que no son números (categóricas)
- 3 Variables en escalas muy distintas

Definición

Un dato faltante (NaN) es un valor que no se registró: una encuesta sin responder, un sensor que falló, etc.

```
df.isna().sum()           # cuantos faltan por columna

df.dropna()               # opcion 1: eliminar filas con faltantes
df.fillna(df.mean())      # opcion 2: completar con la media
```

Datos faltantes: ¿eliminar o completar?

- Eliminar filas: fácil, pero se pierde información si hay muchos faltantes
- Completar con la media/mediana: mantiene el tamaño del dataset, pero inventa un valor

Datos faltantes: ¿eliminar o completar?

- Eliminar filas: fácil, pero se pierde información si hay muchos faltantes
- Completar con la media/mediana: mantiene el tamaño del dataset, pero inventa un valor

No hay una respuesta única, depende de cuántos datos falten y de qué tan importante sea esa columna.

Variables categóricas

Definición

Columnas con categorías en vez de números: color, ciudad, tipo de producto.

Importante

Los modelos de ML trabajan con números. Una columna de texto hay que convertirla antes de entrenar.

One hot encoding

Convierte cada categoría en una columna nueva de ceros y unos.

```
pd.get_dummies(df, columns=["color"])
```

color	color_rojo	color_verde	color_azul
rojo	1	0	0
verde	0	1	0
azul	0	0	1

Ejemplo

Un dataset con edad (0 a 100) y sueldo (0 a 1.000.000). Para el modelo, una diferencia de sueldo de 10.000 "pesa" mucho más que una diferencia de edad de 10 años, solo porque el número es más grande.

Ejemplo

Un dataset con edad (0 a 100) y sueldo (0 a 1.000.000). Para el modelo, una diferencia de sueldo de 10.000 "pesa" mucho más que una diferencia de edad de 10 años, solo porque el número es más grande.

Definición

Escalar significa transformar las variables numéricas para que queden en rangos comparables entre sí.

Escalado: StandardScaler

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_escalado = scaler.fit_transform(X)
```

Cada columna queda con media 0 y desvío estándar 1. Ninguna variable domina a las demás solo por su escala original.

Definición

Separar el dataset en dos partes: una para entrenar el modelo (*train*) y otra que el modelo nunca ve durante el entrenamiento (*test*), para evaluarlo después.

Definición

Separar el dataset en dos partes: una para entrenar el modelo (*train*) y otra que el modelo nunca ve durante el entrenamiento (*test*), para evaluarlo después.

Importante

Evaluar un modelo con los mismos datos que usó para entrenar es como corregir un examen dándole las respuestas al alumno antes de tomarlo.

Train / test split en código

```
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=0
)
```

Una división típica: 70 % para entrenar, 30 % para evaluar.

- numpy, pandas y matplotlib son la base para manipular y ver datos
- Faltantes, categóricas y escalado hay que resolverlos antes de entrenar
- El test set se separa antes de entrenar y no se toca hasta evaluar

¿Preguntas?